

Modelowanie ilości miodu pozyskiwanego z pasiek w zależności od warunków pogodowych

Spis treści

1	WSTĘP TEORETYCZNY	1
2	CEL PROJEKTU	2
3	DANE.....	2
3.1	DANE O ZBIORACH MIODU	2
3.2	DANE O LICZBIE ULI	3
3.3	DANE POGODOWE	3
4	METODOLOGIA.....	4
4.1	PODEJŚCIE REGRESYJNE – UCZENIE MASZYNOWE.....	4
4.1.1	<i>Przygotowanie danych do modelu regresyjnego.....</i>	<i>4</i>
4.1.2	<i>Testowane modele regresyjne.....</i>	<i>5</i>
4.1.3	<i>Walidacja modeli.....</i>	<i>5</i>
4.1.4	<i>Optymalizacja hiperparametrów</i>	<i>6</i>
4.1.5	<i>Metryki oceny modeli</i>	<i>6</i>
4.2	PODEJŚCIE SYMULACYJNE	7
4.2.1	<i>Przygotowanie danych do modelu symulacyjnego</i>	<i>7</i>
4.2.2	<i>Budowa agenta</i>	<i>7</i>
4.2.3	<i>Optymalizacja parametrów</i>	<i>8</i>
4.2.4	<i>Metryki oceny modeli</i>	<i>8</i>
4.2.5	<i>Model dla danych godzinowych.....</i>	<i>8</i>
5	WYNIKI.....	9
5.1	WYNIKI PODEJŚCIA REGRESYJNEGO.....	9
5.2	WYNIKI PODEJŚCIA SYMULACYJNEGO.....	13
6	WNIOSKI.....	15

1 Wstęp teoretyczny

Produkcja miodu w pasiece jest procesem zależnym od wielu czynników środowiskowych, biologicznych i organizacyjnych. Na ilość zebranego miodu wpływają między innymi warunki pogodowe, dostępność pożytków, liczba i siła rodzin pszczelich, termin miodobrania oraz sposób prowadzenia gospodarki pasiecznej. Z tego powodu przewidywanie ilości miodu jest zadaniem złożonym, ponieważ nie zależy wyłącznie od jednej zmiennej, lecz od kombinacji wielu czynników działających w czasie.

Jednym z najważniejszych czynników wpływających na aktywność pszczół są warunki atmosferyczne. Temperatura powietrza wpływa na możliwość wykonywania lotów przez pszczoły, a także na intensywność kwitnienia roślin. Opady ograniczają aktywność lotną pszczół i mogą zmniejszać dostępność nektaru. Silny wiatr również utrudnia loty, przez co może obniżać efektywność zbierania pożytku. Ciśnienie atmosferyczne może natomiast pośrednio odzwierciedlać stabilność warunków pogodowych.

Dane pogodowe mogą więc stanowić istotne źródło informacji przy modelowaniu ilości pozyskiwanego miodu. Należy jednak pamiętać, że zależność pomiędzy pogodą a produkcją miodu nie musi być liniowa. Przykładowo, wzrost temperatury może sprzyjać aktywności pszczół tylko do pewnego momentu, natomiast zbyt wysokie temperatury mogą już pogarszać warunki pracy rodzin pszczelich. Podobnie niewielkie opady mogą wspierać rozwój roślin, ale intensywne opady w okresie pożytku mogą ograniczać loty pszczół.

W projekcie rozważono dwa podejścia do modelowania ilości miodu. Pierwsze podejście opiera się na metodach uczenia maszynowego, w szczególności na modelach regresyjnych, których celem jest znalezienie zależności pomiędzy zmiennymi wejściowymi a ilością zebranego miodu. Drugie podejście ma charakter symulacyjny i próbuje opisać uproszczony mechanizm wpływu pogody na efektywność pracy pszczół.

2 Cel projektu

Celem projektu jest opracowanie modelu pozwalającego przewidywać ilość miodu pozyskiwanego z pasiek na podstawie warunków pogodowych oraz informacji o liczbie uli i terminach miodobrania.

3 Dane

W projekcie wykorzystano trzy główne źródła danych: dane o zbiorach miodu, dane pogodowe oraz dane o liczbie uli w poszczególnych latach.

3.1 Dane o zbiorach miodu

Dane o zbiorach miodu pochodzą z pasiek zlokalizowanych w miejscowości Dubne. Dane zapisano w pliku: *honey.csv*.

Dane pochodzą z 9 pasiek należących do jednego właściciela, zlokalizowanych na jednej łące. Każda pasieka liczy około 10 uli, co daje łącznie w przybliżeniu 100 uli objętych analizą. Zbiór obejmuje 7 lat: 2019-2025. W poszczególnych latach miodobrania nie obejmują identycznych przedziałów czasowych. Zbiory rozpoczynają się zwykle pod koniec czerwca lub w lipcu, a kończą we wrześniu. W pliku znajdują się informacje o:

- Roku miodobrania,
- Numerze tygodnia,
- Ilości zebranego miodu,
- Numerze miodobrania w sezonie.

Dane zostały przyporządkowane do numerów tygodni w roku. Następnie wykonano agregację poprzez zsumowanie obserwacji przypadających na ten sam tydzień.

3.2 Dane o liczbie uli

Informacje o liczbie uli w poszczególnych latach zapisano w pliku *ule.csv*. Zmienna ta jest istotna, ponieważ całkowita ilość zebranego miodu zależy nie tylko od warunków pogodowych, ale również od liczby rodzin pszczelich.

Liczba uli w analizowanych latach była zbliżona do 100, jednak nie była identyczna w każdym sezonie. Dlatego w części analiz wyniki przeliczano również na jeden ul, aby ułatwić porównanie lat między sobą.

Tabela 1. Sumaryczna ilość uli dla poszczególnych lat

year	beehive
2019	92
2020	86
2021	98
2022	100
2023	87
2024	100
2025	96

3.3 Dane pogodowe

Dane pogodowe wykorzystane w projekcie pochodzą z analizy numerycznej **ERA5**. Nie są to wyłącznie bezpośrednie pomiary ze stacji meteorologicznych, ale dane uzyskane w wyniku reanalizy atmosferycznej. Oznacza to, że wartości meteorologiczne są oszacowane dla danego punktu i czasu na podstawie modelu numerycznego oraz dostępnych obserwacji.

W projekcie wykorzystano tygodniowe dane pogodowe z lat 2019–2025. Zostały one uzyskane poprzez agregację oryginalnych danych godzinowych. Zawierają one między innymi następujące zmienne:

- temp – średnia temperatura powietrza,
- wspd – prędkość wiatru,
- prcp – opady,
- pres – ciśnienie atmosferyczne.

Dane pogodowe połączono z danymi o miodzie na podstawie roku i numeru tygodnia. Dzięki temu do każdego miodobrania można było przypisać odpowiadające mu warunki atmosferyczne.

4 Metodologia

W projekcie zastosowano dwa podejścia do modelowania ilości miodu. Pierwsze podejście opierało się na metodach uczenia maszynowego, w szczególności na modelach regresyjnych, których celem było przewidywanie ilości zebranego miodu na podstawie danych pogodowych, liczby uli oraz informacji o miodobraniu. Drugie podejście miało charakter symulacyjny i polegało na opisanu uproszczonego mechanizmu wpływu warunków pogodowych na efektywność pracy pszczół.

Dalsza część metodyki została podzielona na dwa podrozdziały: podejście regresyjne oraz podejście symulacyjne.

4.1 Podejście regresyjne – uczenie maszynowe

W części opartej na uczeniu maszynowym celem było zbudowanie modelu regresyjnego przewidującego ilość zebranego miodu na podstawie danych pogodowych, liczby uli oraz informacji o miodobraniu.

4.1.1 Przygotowanie danych do modelu regresyjnego

Połączono trzy główne źródła danych: dane o zbiorach miodu, tygodniowe dane pogodowe oraz dane o liczbie uli. Dane o miodzie i pogodzie zostały połączone na podstawie roku oraz numeru tygodnia, natomiast liczba uli została dodana na podstawie roku.

W modelu wykorzystano między innymi następujące zmienne:

- year — rok,
- week — numer tygodnia,
- harvest — numer miodobrania,
- beehive — liczba uli w danym roku,
- temp — średnia temperatura,
- wspd — prędkość wiatru,
- prcp — opady,
- pres — ciśnienie atmosferyczne.

Dodatkowo do modelu dodano cechy pogodowe z wybranych wcześniejszych tygodni sezonu. Dane pogodowe zostały przekształcone do postaci szerokiej, tak aby model mógł korzystać z informacji o warunkach pogodowych z różnych tygodni, np. *temp_23*, *prcp_21*, *pres_25*.

Zmienną objaśnianą w modelu była ilość zebranego miodu, czyli kolumna honey. Pozostałe zmienne, takie jak pogoda, numer tygodnia, numer miodobrania oraz liczba uli, zostały wykorzystane jako zmienne wejściowe modelu.

4.1.2 Testowane modele regresyjne

W ramach podejścia regresyjnego przetestowano kilka modeli uczenia maszynowego. Celem było sprawdzenie, które podejście najlepiej radzi sobie z przewidywaniem ilości zebranego miodu na podstawie przygotowanych zmiennych wejściowych.

Do porównania wybrano zarówno modele liniowe, jak i modele nieliniowe. Modele liniowe są prostsze i bardziej stabilne przy małej liczbie obserwacji, natomiast modele nieliniowe mogą wychwytywać bardziej złożone zależności pomiędzy pogodą a ilością miodu.

Wykorzystano następujące modele:

Tabela 2. Wykorzystane modele liniowe oraz nieliniowe

Model	Opis
Ridge	regresja liniowa z regularyzacją L2, ograniczająca zbyt duże współczynniki
ElasticNet	regresja liniowa łącząca regularyzację L1 i L2, umożliwiającą częściową selekcję cech
HuberRegressor	model liniowy odporniejszy na obserwacje odstające
RandomForestRegressor	model oparty na wielu drzewach decyzyjnych
ExtraTreesRegressor	wariant lasu drzew z większą losowością przy tworzeniu podziałów
GradientBoostingRegressor	model budujący kolejne drzewa w celu poprawiania błędów poprzednich
SVR	regresja wektorów nośnych, pozwalająca modelować zależności nieliniowe

Wszystkie wymienione modele zostały wykorzystane do wstępnego porównania jakości predykcji. W dalszej części raportu szczegółowo przedstawiono wyniki dla modeli **ElasticNet** oraz **Ridge**, ponieważ uzyskały one najlepsze rezultaty. Pozostałe modele potraktowano jako modele porównawcze, służące do sprawdzenia, czy bardziej złożone podejścia poprawiają jakość predykcji.

4.1.3 Walidacja modeli

Do oceny jakości modeli nie zastosowano losowego podziału danych na zbiór treningowy i testowy. Dane mają charakter sezonowy, dlatego losowe mieszanie obserwacji mogłoby prowadzić do zbyt optymistycznych wyników. W takim przypadku część miodobrań z tego samego roku mogłaby znaleźć się w zbiorze treningowym, a część w testowym, przez co model częściowo „znałby” dany sezon.

Zamiast tego wykorzystano metodę *LeaveOneGroupOut*, gdzie grupą był rok. Oznacza to, że w każdej iteracji jeden cały rok był traktowany jako zbiór testowy, a model trenowano na danych z pozostałych lat.

Przykład podziału:

- Trening: 2019, 2020, 2021, 2022, 2024, 2025

- Test: 2023

Takie podejście pozwala sprawdzić, czy model potrafi przewidywać wyniki dla sezonu, którego wcześniej nie widział. Jest to bardziej zbliżone do praktycznego zastosowania modelu, w którym chcemy prognozować ilość miodu w kolejnym roku na podstawie danych historycznych.

4.1.4 Optymalizacja hiperparametrów

Po wstępnym porównaniu modeli wykonano optymalizację hiperparametrów dla dwóch najlepszych modeli, czyli **Ridge** oraz **ElasticNet**. Do strojenia parametrów wykorzystano **bibliotekę Optuna**, która automatycznie przeszukuje zadany zakres wartości i wybiera konfigurację dającą najniższy błąd predykcji.

Dla modelu **Ridge** optymalizowano **parametr alpha**, który określa siłę regularyzacji. Większa wartość alpha mocniej ogranicza współczynniki modelu, co może zmniejszać ryzyko przeuczenia.

Dla modelu **ElasticNet** optymalizowano dwa parametry:

- **alpha** – odpowiadająca za siłę regularyzacji,
- **l_ratio** - odpowiadającego za proporcję między regularyzacją L1 i L2

Tabela 3. Najlepsze uzyskane parametry po dokonaniu optymalizacji

Model	Najlepsze parametry
Ridge	alpha = 15,615
ElasticNet	alpha = 4,398, l1 ratio = 0,998

Wartość **l1_ratio** bliska 1 oznacza, że **model ElasticNet** działał podobnie do **regresji Lasso**, czyli oprócz regularyzacji wykonywał również selekcję cech. Dzięki temu część mniej istotnych zmiennych mogła otrzymać współczynniki bliskie zeru.

4.1.5 Metryki oceny modeli

Do oceny jakości modeli regresyjnych wykorzystano kilka miar błędu. Ponieważ przewidywana zmienna, czyli ilość miodu, jest wartością liczbową, nie stosowano klasycznej dokładności znanej z klasyfikacji. Zamiast tego oceniano, o ile kilogramów lub o jaki procent model myli się względem wartości rzeczywistych.

Tabela 4. Wykorzystane metryki do oceny modeli regresyjnych

Metryka	Znaczenie
MAE	średni błąd bezwzględny, czyli przeciętna pomyłka modelu w kilogramach
RMSE	pierwiastek średniego błędu kwadratowego, mocniej karze duże pojedyncze błędy

błąd procentowy	pokazuje, jaki procent wartości rzeczywistej stanowi błąd predykcji
błąd na ul	pokazuje pomyłkę modelu w przeliczeniu na jeden ul

Najważniejszą metryką było MAE, ponieważ jest najbardziej intuicyjne w interpretacji. Przykładowo wartość $MAE = 35,5$ kg oznacza, że model myli się średnio o około 35,5 kg dla jednego miodobrania.

Dodatkowo analizowano wyniki w skali rocznej, czyli porównywano sumę rzeczywistego i przewidywanego miodu w danym roku. Pozwoliło to sprawdzić, czy model dobrze odwzorowuje całkowitą produkcję miodu w sezonie, nawet jeśli popełnia większe błędy dla pojedynczych miodobrań.

4.2 Podejście symulacyjne

W części symulacyjnej celem było stworzenie modelu agentowego pozwalającego oszacować ilość wyprodukowanego miodu w badanych pasiekach na podstawie warunków pogodowych. Model umożliwiał analizę wpływu czynników atmosferycznych na produkcję miodu oraz symulację przewidywanej jego ilości.

4.2.1 Przygotowanie danych do modelu symulacyjnego

W podejściu symulacyjnym wykorzystano dane dotyczące zbiorów miodu, warunków pogodowych oraz liczby uli, tworząc spójny zbiór zmiennych wejściowych i zmiennej docelowej. Model opierał się na rzeczywistych parametrach środowiskowych, takich jak temperatura, wiatr, opady oraz ciśnienie atmosferyczne, które wpływały na aktywność pszczół i przewidywaną produkcję miodu.

W odróżnieniu od podejścia regresyjnego nie tworzone cech historycznych. Zamiast tego w modelu symulacyjnym zastosowano zależności pomiędzy zmiennymi opisane za pomocą funkcji wydajności pszczół, odwzorowującej biologiczny wpływ warunków środowiskowych na efektywność kolonii pszczelich.

4.2.2 Budowa agenta

Centralnym elementem modelu była funkcja **bee_efficiency**, która modelowała wpływ warunków środowiskowych - temperatury, wiatru, opadów oraz ciśnienia atmosferycznego, na aktywność pszczół w skali od 0 do 1. Każdy z czynników środowiskowych wpływał na efektywność w sposób ciągły, a końcowa wartość stanowiła ich łączny efekt.

Na podstawie wyznaczonej efektywności funkcja **simulate_honey** obliczała przewidywaną produkcję miodu, uwzględniając zarówno aktywność pszczół, liczbę uli, jak i parametr bazowej wydajności pasieki.

4.2.3 Optymalizacja parametrów

Optymalizacja parametrów modelu odbywała się przy użyciu algorytmu genetycznego. Każdy zestaw parametrów traktowany był jako osobnik w populacji, a proces optymalizacji obejmował iteracyjne generacje, w których zachodziły selekcja, mutacja oraz krzyżowanie. Najlepsze rozwiązania były zachowywane dzięki mechanizmowi elitaryzmu, co stabilizowało proces uczenia. Parametry takie jak intensywność mutacji, jej częstość oraz udział elity kontrolowały dynamikę eksploracji przestrzeni rozwiązań.

W efekcie model nie opierał się na klasycznej regresji, lecz na iteracyjnej symulacji procesu biologicznego, w którym parametry środowiskowe i behawioralne pszczoł były dostrajane tak, aby minimalizować błąd predykcji produkcji miodu względem danych rzeczywistych.

Optymalizacja parametrów pozwoliła uzyskać zestaw najlepszych wartości, przedstawionych w Tabeli 5.

Tabela 5. Wartości parametrów modelu

Parametr	Wartość
temp_low	7,6977
temp_high	16,2896
wind_penalty	0,7316
rain_penalty	-0,0597
pres_penalty	0,0238
base_efficiency	2,7924

4.2.4 Metryki oceny modeli

Ocena jakości modelu była realizowana przez funkcję loss, która porównywała wartości przewidywane z rzeczywistymi danymi dotyczącymi zbiorów miodu. W ocenie jakości zastosowano metryki RMSE oraz MAE, analogicznie jak w modelu regresyjnym. RMSE pozwalało na bezpośrednią interpretację wielkości błędu w tych samych jednostkach co dane, natomiast MAE umożliwiało bardziej intuicyjne określenie średniego odchylenia predykcji od wartości rzeczywistych. Dodatkowo przeprowadzono analizę w skali rocznej, porównując sumę rzeczywistej i przewidywanej produkcji miodu w poszczególnych latach.

4.2.5 Model dla danych godzinowych

Podjęto próbę wykorzystania danych godzinowych, jednak mimo że udało się przeprowadzić obliczenia dla takiej rozdzielczości czasowej, uzyskane wyniki okazały się mniej satysfakcjonujące niż w przypadku danych tygodniowych. Dodatkowo analiza danych godzinowych wiązała się z bardzo dużym czasem obliczeń oraz wysokimi wymaganiami dotyczącymi zasobów obliczeniowych. Z tego względu zdecydowano się skupić na danych tygodniowych, które pozwoliły uzyskać lepsze rezultaty przy jednoczesnym ograniczeniu kosztów obliczeniowych.

5 Wyniki

W tej części przedstawiono wyniki uzyskane dla dwóch podejść zastosowanych w projekcie: podejścia regresyjnego oraz podejścia symulacyjnego. Wyniki oceniano przede wszystkim na podstawie błędów predykcji, czyli różnicy pomiędzy rzeczywistą a przewidywaną ilością zebranego miodu.

5.1 Wyniki podejścia regresyjnego


Tabela 6. Porównanie modeli regresyjnych przed optymalizacją hiperparametrów

Model	MAE	RMSE
ElasticNet	43,90	54,68
Ridge	44,14	54,72
ExtraTrees	46,36	58,09
Huber	48,80	61,15
RandomForest	49,36	62,60
GradientBoosting	53,05	66,99
SVR	58,97	75,26

W podejściu regresyjnym najlepsze wyniki uzyskały modele liniowe z regularyzacją, szczególnie tak jak wyżej już wspomniano **ElasticNet** oraz **Ridge**. Po optymalizacji hiperparametrów (wyniki Tabela 7) najlepszy wynik uzyskał model ElasticNet, dlatego dalszą analizę przeprowadzono głównie dla tego modelu.

Tabela 7. Porównanie najlepszych modeli regresyjnych po optymalizacji

Model	Najlepsze parametry	MAE
Ridge	alpha = 15,615	43,77
ElasticNet	alpha = 4,398, 11 ratio = 0,998	38,43



Rysunek 1. Porównanie MAE modeli Ridge i ElasticNet

Błędy dla pojedynczych miodobrań

Dla **modelu ElasticNet** policzono błędy na poziomie pojedynczych miodobrań. Każdy wiersz odpowiada jednemu miodobraniu, a nie całemu rokowi.

Tabela 8. Podsumowanie błędów dla pojedynczych miodobrań

Metryka	Wartość
Średni błąd bezwzględny MAE	35,50 kg
Maksymalny błąd bezwzględny	138,45 kg

Średni błąd bezwzględny oznacza, że model mylił się przeciętnie o około 35,50 kg dla jednego miodobrania. Maksymalny błąd bezwzględny oznacza największą pojedynczą pomyłkę modelu w całym zbiorze danych.

Błędy według roku

Następnie sprawdzono, jak duże były błędy modelu w poszczególnych latach. Pozwala to ocenić, w których sezonach model radził sobie lepiej, a w których gorzej.

Tabela 9. Średni błąd bezwzględny modelu ElasticNet według roku

Rok	Średni błąd bezwzględny
2019	14,49
2020	82,28
2021	37,24
2022	41,63
2023	37,88
2024	19,71
2025	10,08

Największy średni błąd wystąpił w roku 2020, natomiast najmniejsze błędy uzyskano dla lat 2025, 2019 i 2024.


Suma rzeczywistego i przewidywanego miodu w skali roku

Oprócz błędów dla pojedynczych miodobrań porównano również sumaryczną ilość rzeczywistego i przewidywanego miodu w skali całego roku. Jest to istotne, ponieważ model może popełniać błędy dla pojedynczych miodobrań, ale nadal dobrze odwzorowywać całkowitą produkcję w sezonie.

Tabela 10. Porównanie rzeczywistej i przewidywanej sumy miodu według roku

Rok	Rzeczywisty miód	Przewidywany miód	Różnica
2019	592,00	644,66	52,66
2020	1495,20	1428,04	-67,16
2021	1563,80	1554,49	-9,31
2022	1489,60	1440,85	-48,75
2023	847,70	797,00	-50,70
2024	979,30	1051,87	72,57
2025	877,80	928,49	50,69

W ujęciu rocznym model uzyskał stabilne wyniki. Najlepsze dopasowanie roczne wystąpiło dla 2021 roku, gdzie różnica między rzeczywistą a przewidywaną sumą miodu wyniosła tylko - 9,31 kg.



Rysunek 2. Rzeczywisty i przewidywany miód w kolejnych miodobraniach

Wyniki w przeliczeniu na jeden ul

Ponieważ liczba uli w poszczególnych latach nie była identyczna, dodatkowo porównano wyniki w przeliczeniu na jeden ul.

Tabela 11. Rzeczywisty i przewidywany miód w przeliczeniu na jeden ul

Rok	Liczba uli	Rzeczywisty miód na ul	Przewidywany miód na ul
2019	92	6,43	7,01
2020	86	17,39	16,61
2021	98	15,96	15,86
2022	100	14,90	14,41
2023	87	9,74	9,16
2024	100	9,79	10,52
2025	96	9,14	9,67

Przeliczenie na ul pozwala lepiej porównywać sezony między sobą, ponieważ eliminuje część wpływu różnej liczby uli w poszczególnych latach.

5.2 Wyniki podejścia symulacyjnego

Najlepsze wyniki uzyskano dla parametrów przedstawionych w Tabeli 5. Analiza parametrów wskazuje, że największy wpływ na badaną zmienną mają czynniki temperaturowe, szczególnie wysoka temperatura. Oznacza to, że wzrost temperatury istotnie zwiększa efektywność analizowanego procesu. Również niska temperatura wpływa dodatnio, choć w mniejszym stopniu.

Czynniki atmosferyczne takie jak wiatr, opady oraz ciśnienie mają relatywnie niewielkie znaczenie. Najbardziej zauważalny spośród nich jest wpływ wiatru, który obniża wartość wskaźnika. Opady deszczu oraz ciśnienie atmosferyczne wykazują marginalny wpływ na końcowy wynik modelu.

Wartość `base_efficiency` reprezentuje bazowy poziom efektywności, od którego rozpoczyna się działanie modelu przed uwzględnieniem wpływu poszczególnych czynników pogodowych.

Ogólnie model sugeruje, że temperatura jest kluczowym determinantem badanego zjawiska, natomiast pozostałe warunki pogodowe pełnią rolę pomocniczą i mają ograniczony wpływ na wynik końcowy.

Tabela 12. Podsumowanie błędów dla modelu symulacyjnego

Metryka	Wartość
RMSE	70,8644
MAE	48,8663

W porównaniu z najlepszym modelem regresyjnym model symulacyjny osiągnął słabsze wyniki predykcyjne. Analiza metryk błędu MAE oraz RMSE wskazuje, że model symulacyjny generował większe odchylenia pomiędzy wartościami rzeczywistymi a prognozowanymi. Średni błąd predykcji był wyższy o około 13,37 kg miodu, co świadczy o niższej dokładności modelu symulacyjnego względem modelu regresyjnego. Dodatkowo wyższa wartość RMSE sugeruje, że model symulacyjny był bardziej podatny na występowanie większych błędów jednostkowych.

Suma rzeczywistego i przewidywanego miodu w skali roku


Tabela 14. Porównanie rzeczywistej i przewidywanej sumy miodu według roku

Rok	Rzeczywisty miód	Przewidywany miód	Różnica
2019	592,00	753,91	161,91
2020	1495,20	824,71	-670,49
2021	1563,80	1467,11	-96,69
2022	1489,60	1584,10	94,50
2023	847,70	678,27	-169,43

2024	979,30	1097,52	118,22
2025	877,80	1111,02	233,22

W ujęciu rocznym model wykazał umiarkowanie dobrą zgodność z danymi rzeczywistymi. Widoczna jest zmienność dokładności w poszczególnych latach. Najlepsze dopasowanie uzyskano dla roku 2022, gdzie różnica między wartością rzeczywistą a przewidywaną wyniosła 94,50 kg. W pozostałych latach obserwuje się zarówno przeszacowania, jak i niedoszacowania produkcji miodu. Na przykład w 2020 roku model znacząco zaniżył wynik, natomiast w 2019 oraz 2025 roku wystąpiło wyraźne przeszacowanie produkcji.

Mimo tych odchyłeń model zachowuje zdolność do uchwycenia ogólnego trendu zmian produkcji miodu w czasie, co wskazuje na jego użyteczność w analizach porównawczych i prognozowaniu długoterminowym.



Rysunek 3. Rzeczywisty i przewidywany miód w kolejnych miodobraniach

Wyniki w przeliczeniu na jeden ul

Dodatkowo porównano wyniki w przeliczeniu na jeden ul.

Tabela 15. Rzeczywisty i przewidywany miód w przeliczeniu na jeden ul

Rok	Liczba uli	Rzeczywisty miód na ul	Przewidywany miód na ul
2019	92	6,43	8,19
2020	86	17,39	9,59
2021	98	15,96	14,97
2022	100	14,90	15,87
2023	87	9,74	7,80
2024	100	9,79	10,98
2025	96	9,14	11,57

Można zauważyć, że różnice pomiędzy wynikami przedstawionymi w Tabeli 15 i Tabeli 11 nie są znaczące, jednakże w ujęciu całościowym skali analizowanych danych stają się one już wyraźniej dostrzegalne i bardziej czytelne.

6 Wnioski

W podejściu regresyjnym najlepsze wyniki uzyskały modele liniowe z regularyzacją, przede wszystkim **Ridge** oraz **ElasticNet**. Oznacza to, że dla dostępnego zbioru danych **prostsze modele okazały się stabilniejsze niż bardziej złożone metody**, takie jak *RandomForest*, *GradientBoosting* czy *SVR*. Prawdopodobnie wynika to z niewielkiej liczby obserwacji oraz dużej liczby cech pogodowych.

Model ElasticNet pozwolił uzyskać dobre wyniki predykcji dla pojedynczych miodobrań. Średni błąd bezwzględny wyniósł około 35,5 kg, co oznacza, że model przeciętnie mylił się o tę wartość dla jednego miodobrania. Największe błędy pojawiały się w przypadkach nietypowych zbiorów, szczególnie wtedy, gdy rzeczywista ilość miodu była bardzo wysoka lub bardzo niska względem pozostałych obserwacji.

Analiza wyników rocznych pokazała, że mimo błędów na poziomie pojedynczych miodobrań model dobrze odwzorowywał sumaryczną produkcję miodu w skali roku. Różnice między rzeczywistą a przewidywaną sumą roczną były stosunkowo niewielkie, szczególnie dla roku 2021, gdzie różnica wyniosła tylko około 9 kg.

Przeliczenie wyników na jeden ul pozwoliło lepiej porównać poszczególne lata, ponieważ liczba uli nie była stała w całym analizowanym okresie. W tym ujęciu model również dość dobrze odwzorowywał ogólny poziom produkcji miodu w kolejnych latach.

Test danych godzinowych bez agregacji nie poprawił jakości modelu. Wynika to z faktu, że ilość miodu jest mierzona na poziomie miodobrania, a nie pojedynczej godziny. Bezpośrednie przypisanie tej samej wartości miodu do wielu rekordów godzinowych sztucznie zwiększa liczbę obserwacji i może zaburzać proces uczenia.

Znacznie słabsze wyniki uzyskano natomiast dla modelu symulacyjnego. Model ten miał większe trudności z poprawnym odwzorowaniem rzeczywistych wartości produkcji miodu zarówno na poziomie pojedynczych miodobrań, jak i sum rocznych. W porównaniu do modeli regresyjnych błędy predykcji były wyższe, a przewidywane wartości częściej odbiegały od danych rzeczywistych.

Prawdopodobnie wynika to z faktu, że model symulacyjny opiera się na większej liczbie założeń i uproszczeń dotyczących wpływu warunków pogodowych na aktywność pszczół oraz produkcję miodu. Przy ograniczonej liczbie obserwacji oraz dużej zmienności warunków środowiskowych trudniej było poprawnie odwzorować rzeczywiste zależności. Ostatecznie lepszą skuteczność oraz większą stabilność predykcji wykazały modele regresyjne.